

Lecture 6 : 적분 / 미분방정식

Fastcampus Math Camp

신승우

Saturday 30th June, 2018

Vector/Scalar Field

Vector Field란 공간 위의 한 점을 벡터 하나로 대응시키는 함수를 말한다. 역으로, Scalar Field란 공간 위의 한 점을 실수 하나로 대응시키는 함수를 말한다.


Vector Field는 벡터함수로 볼 수 있고, Scalar Field는 스칼라함수로 볼 수 있다.

스칼라 함수 f 에 대해서, 그 함수의 gradient ∇f 는 다음과 같이 정의된다.

Gradient ∇f

$$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right) = \frac{\partial f}{\partial x} \hat{x} + \frac{\partial f}{\partial y} \hat{y} + \frac{\partial f}{\partial z} \hat{z}$$

Gradient II



함수의 그래디언트는 함수가 만드는 곡면에서의 기울기를 나타내는 벡터라고 할 수 있다. 그래디언트의 각 항을 살펴보면, \hat{x} 항은 곧 곡면을 x 축에 평행하게 자른 성분의 미분이라고 볼 수 있다.

스칼라 함수 f, g 와 상수 a, b 에 대해서 다음이 성립한다.

- $\nabla(af + bg) = a\nabla f + b\nabla g$
- $\nabla fg = f(\nabla g) + (\nabla f)g$

Proof for 1)

$$\nabla(af + bg) = \sum_i \frac{\partial(af + bg)}{\partial x_i} \quad (1)$$

$$= \sum_i \left[a \frac{\partial f}{\partial x_i} + b \frac{\partial g}{\partial x_i} \right] \quad (2)$$

$$= a \sum_i \frac{\partial f}{\partial x_i} + b \sum_i \frac{\partial g}{\partial x_i} \quad (3)$$

$$= a \nabla f + b \nabla g \quad (4)$$

Proof for 2)

$$\nabla fg = \sum_i \frac{\partial(fg)}{\partial x_i} \quad (5)$$

$$= \sum_i \left[f \frac{\partial g}{\partial x_i} + g \frac{\partial f}{\partial x_i} \right] \quad (6)$$

$$= f \sum_i \frac{\partial g}{\partial x_i} + g \sum_i \frac{\partial f}{\partial x_i} \quad (7)$$

$$= f \nabla g + g \nabla f \quad (8)$$

Gradient의 활용 : Directional Derivative

함수 f 에 대해서, 특정 방향으로의 미분값을 Directional Derivative라 한다.
함수 f 의 벡터 \vec{a} 로의 Directional Derivative는 다음과 같이 정의된다.

$$\nabla_{\vec{a}} f(\vec{x}) = \lim_{h \rightarrow 0} \frac{f(\vec{x} + h\vec{a}) - f(\vec{x})}{h} \quad (9)$$

이는 그래디언트를 이용하여 다음과 같이 계산될 수 있다.

$$\nabla_{\vec{a}} f(\vec{x}) = \nabla f(\vec{x}) \bullet \vec{a} \quad (10)$$

위 Directional Derivative의 정의는 아래와 같이 쓰일 수 있다.

$$\nabla_{\vec{a}} f(\vec{x}) = \lim_{h \rightarrow 0} \frac{f(\vec{x} + h\vec{a}) - f(\vec{x})}{h} = \frac{dF}{dk} \quad (11)$$

이 때, $F(k) = f(\vec{x} + h\vec{a})$ 이고, $k = \vec{x} + h$ 이다. 이 때, chain rule에 따라서 다음과 같이 정리할 수 있다.

$$\frac{dF}{dh} = \sum_i \frac{\partial f}{\partial x_i} \frac{dh}{dx_i} \quad (12)$$

$$= \sum_i \frac{\partial f}{\partial x_i} \frac{dh}{dx_i} \quad (13)$$

$$= \sum_i \frac{\partial f}{\partial x_i} \vec{a}_i \quad (14)$$

$$= \nabla f \bullet \vec{a} \quad (15)$$

Gradient의 활용 : Multivariate Taylor Expansion

스칼라함수 $f(\vec{r})$ 에 대해서, 다음이 성립한다.

$$f(\vec{r} + \vec{\delta}t) = f(\vec{r}) + [\vec{a} \bullet \nabla f(\vec{r})]t + \frac{1}{2!}[\vec{a} \bullet \nabla]^2 t^2 + \dots \quad (16)$$

즉, 그래디언트는 어떠한 한 점 근방에서 함수를 원하는 차수의 다항식으로 근사하는 것에 쓰일 수 있다.

Hessian 행렬과 최적화 I

스칼라 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 에 대해서, hessian 행렬 H 는 다음과 같이 정의된다.

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \quad (17)$$

이런 Hessian Matrix가 가지는 의미는, 어떤 점 근처에서 원함수 f 를 근사하는 2차함수를 만들어낸다는 점이다. 예를 들어서, f 가 실수에서 실수로 가는 함수라고 하자. 이 때는 $H = \frac{d^2 f}{dx^2}$ 일 것이다. 즉 이 함수는 테일러급수의 2차항이라고 생각할 수 있다. 이와 비슷하게, 위에서 살펴본 식을 변형하면 n 변수 함수에 대해서는 테일러급수의 일반화로 다음이 성립한다.

$$f(\vec{x} + \vec{\delta}) \approx f(\vec{x}) + \nabla f(\vec{x})^T \vec{\delta} + \frac{1}{2!} \vec{\delta}^T H(\vec{x}) \vec{\delta} \quad (18)$$

Hessian 행렬과 최적화 II

이 식을 이용하여 Hessian Matrix를 이용해서 다음을 해 볼 수 있다.

- Second Derivative Test
- 최적화


에 사용된다. 아래에서 각자의 영역에서 어떻게 사용되는지 살펴보겠다. 먼저 Second Derivative Test를 살펴보겠다. 먼저, 앞서 수업에서 극값은 다음의 조건을 만족하는 것이 필요조건이라고 하였다.

$$\frac{\partial f}{\partial x_i} = 0 \quad (19)$$

이 때, 위 경우를 만족하면서 극값이 아닌 점을 saddle point라고 한다. 이러한 점을 가려내기 위해서 1변수에서는 2계도함수를 이용하여 판별하였다. 다변수함수의 경우, Hessian Matrix의 고윳값의 부호를 이용해서 테스트할 수 있다. 즉, 만약 어떤 점 x 에서 H 의 고윳값이 모두 양수라면 local minimum을 가지고, 모두 음수라면 local maximum을

Hessian 행렬과 최적화 III

가지며, 둘 다 아니라면 saddle point가 된다. 예컨대, 다음의 함수를 생각해 보자.



$$f(x, y) = (x + y)(xy + xy^2)$$

Hessian 행렬과 최적화 IV

이 함수는 $(0,0)$, $(0,-1)$, $(1,-1)$, $(\frac{3}{8}, -\frac{3}{4})$ 에서 $\frac{\partial z}{\partial x} = 0$, $\frac{\partial z}{\partial y} = 0$ 를 만족한다. 이 때, 이 함수의 Hessian 행렬을 구해서 각각의 행렬식을 계산하면 된다. 계산 결과는 다음과 같다.

$$D(0,0) = 0 \quad (20)$$

$$D(0,-1), D(1,-1) < 0 \quad (21)$$

$$D(\frac{3}{8}, -\frac{3}{4}) > 0 \quad (22)$$

즉, 두 점에서 saddle point이며 한 점에서는 local maximum을 가지는 것을 알 수 있다. 그리고 $(0,0)$ 에서는 이차 미분으로 판별이 불가능하므로, 더 고차 미분을 이용하여 판별하여야 한다.

두 번째로 최적화에서의 Hessian Matrix를 살펴보겠다. 다시 위 식을 살펴보면, 2차식까지의 근사를 위해서는 Hessian Matrix를 계산하여야 함을 알 수 있다. 즉, n 차원의 경우 이를 저장하는 데 n^2 의 공간과 시간이 필요하다. 이를 해결하기 위해서 일반적으로 Hessian을 직접 계산하는

것이 아니라, 함수의 그래디언트를 미리 계산하여 Hessian을 선형 operator로만 사용하는 것이다. 자세하게는 다음과 같다.
먼저, 다음 식이 성립한다.

$$\nabla f(\vec{x} + \vec{\delta}) \approx \nabla f(\vec{x}) + H(\vec{x})\vec{\delta} \quad (23)$$

따라서 $H\vec{\delta} \approx \nabla f(\vec{x} + \vec{\delta}) - \nabla f(\vec{x})$ 이므로, 위 $f(\vec{x} + \vec{\delta})$ 를 계산할 때 Hessian을 계산하는 것이 아니라 그래디언트를 계산하게 된다. 이에 따라서 계산복잡도는 $O(n)$ 이 되어 계산을 효율적으로 수행할 수 있다.

Divergence의 정의

벡터함수 \vec{F} 에 대해서 그 divergence는 ∇ 와의 내적으로 정의된다. 즉,

Divergence $\nabla \bullet \vec{F}$

$$\nabla \bullet \vec{F} = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y}, \frac{\partial}{\partial z} \right) \bullet \vec{F} = \frac{\partial F_x}{\partial x} + \frac{\partial F_y}{\partial y} + \frac{\partial F_z}{\partial z}$$

이다.

Divergence의 성질

상수 a, b 와 스칼라함수 f , 벡터함수 \vec{F}, \vec{G} 에 대해서 다음이 성립한다.

- $\nabla \bullet (a\vec{F} + b\vec{G}) = a\nabla \bullet \vec{F} + b\nabla \bullet \vec{G}$
- $\nabla \bullet (f\vec{F}) = (\nabla f)\vec{F} + f\nabla \bullet \vec{F}$

벡터함수 \vec{F} 에 대해서 그 divergence는 ∇ 와의 외적으로 정의된다. 즉,

Divergence $\nabla \bullet \vec{F}$

$$\nabla \bullet \vec{F} = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y}, \frac{\partial}{\partial z} \right) \times \vec{F}$$

상수 a, b 와 스칼라함수 f , 벡터함수 \vec{F}, \vec{G} 에 대해서 다음이 성립한다.

- $\nabla \times (a\vec{F} + b\vec{G}) = a\nabla \times \vec{F} + b\nabla \times \vec{G}$
- $\nabla \times (f\vec{F}) = (\nabla f) \times \vec{F} + f\nabla \times \vec{F}$
- $\nabla \times (\vec{F} \times \vec{G}) = \vec{F}(\nabla \cdot \vec{G}) - \vec{G}(\nabla \cdot \vec{F}) + (\vec{G} \cdot \nabla)\vec{F} - (\vec{F} \cdot \nabla)\vec{G}$


Chain Rule

- $\nabla f(g(\vec{x})) = f'g(\vec{x})\nabla g(x)$
- $\nabla f(\vec{A}(\vec{x})) = \nabla f(\vec{A}(\vec{x}))\nabla \vec{A}$
- $\nabla \bullet \vec{A}(f(\vec{x})) = \vec{A}'(f(\vec{x}))\nabla f$
- $\nabla \times (\vec{A}(f(\vec{x}))) = -\vec{A}'(f(\vec{x})) \times \nabla f$

Second Derivatives

- Curl of the Gradient : $\nabla \times (\nabla f) = \vec{0}$
- Divergence of the Curl : $\nabla \bullet (\nabla \times \vec{A}) = 0$
- Divergence of the Gradient : $\nabla(\nabla f) = \nabla^2 f$
- Curl of the Curl : $\nabla \times (\nabla \times \vec{A}) = \nabla(\nabla \bullet \vec{A}) - \nabla^2 \vec{A}$

적분의 정의 : 리만 합



어떤 함수 f 의 정적분 $\int_{x=a}^{x=b} f(x)dx$ 는 다음과 같이 정의된다.

$$S = \int_{x=a}^{x=b} f(x)dx = \lim_{n \rightarrow \infty} \sum_i f\left(a + \frac{(b-a)i}{n}\right) \delta \quad (24)$$

적분의 정의 : 미분의 역과정

어떤 함수 f 의 부정적분 $F = \int f(x)dx$ 는 다음을 만족하는 함수로 정의된다.

$$\frac{dF}{dx} = f \quad (25)$$

정적분과 부정적분

이 때, 어떤 함수의 a 부터 b 까지의 정적분 $S = \int_{x=a}^{x=b} f(x)dx$ 와 함수 f 의 부정적분 $F(x)$ 사이에는 다음의 관계가 성립한다.

$$F(b) - F(a) = \int_{x=a}^{x=b} f(x)dx \quad (26)$$

이를 미적분학의 기본정리라고 한다.

두 함수의 곱의 미분공식을 생각해보자.

$$\frac{d(fg)}{dx} = f \frac{dg}{dx} + \frac{df}{dx} g \quad (27)$$

이제, 양변을 x 로 적분하면 적분의 정의에 의해서 다음과 같다.

$$fg = \int f \frac{dg}{dx} + \int \frac{df}{dx} g dx \quad (28)$$

$$\int f \frac{dg}{dx} = fg - \int \frac{df}{dx} g dx \quad (29)$$

위와 같은 방식으로 수행하는 적분을 부분적분이라 한다.

부분적분의 예시 : $\int e^x \sin(x) dx$

여기서 $f = e^x$, $\frac{dg}{dx} = \sin(x)$ 로 잡고 다음과 같이 부분적분을 수행한다.

$$\int e^x \sin(x) dx = -e^x \cos(x) - \int -\cos(x) e^x dx \quad (30)$$

$$= -e^x \cos(x) + \int e^x \cos(x) \quad (31)$$

여기서 다시 $\int e^x \cos(x)$ 를 위와 비슷하게 부분적분하면 아래와 같다.

$$\int e^x \cos(x) dx = e^x \sin(x) - \int e^x \sin x \quad (32)$$

이를 위 식에 대입하면, 다음이 성립한다.

$$\int e^x \sin(x) = \frac{e^x}{2} (\sin(x) - \cos(x)) \quad (33)$$

부분적분의 예시 : $\int \sin^n(x) dx$

$$I_n = \frac{-\cos(x)\sin^{n-1}(x)}{n} + \frac{n-1}{n} I_{n-2} \quad (34)$$

위 부분적분에서 곱셈의 미분을 생각했듯이, chain rule을 이용한 합성함수의 미분을 생각해 보자.

$$\frac{df(g(x))}{dx} = f'(g(x)) \frac{dg}{dx} \quad (35)$$

$$f(g(x)) = \int f'(g(x)) \frac{dg}{dx} dx \quad (36)$$

즉, 함수 f 의 꼴을 볼 때, 어떤 적절한 치환 $g(x)$ 를 이용하여 적분을 간단히 할 수 있다.

치환적분의 예시 : 삼각함수로의 치환

$\int \frac{dx}{\sqrt{1-x^2}}$ 에서, $x = \cos(t)$ 로의 치환을 생각해 보자. 이 때 $\frac{dx}{dt} = -\sin(t)$ 가 되므로, 다음과 같이 원 식을 계산할 수 있다.

$$\int \frac{dx}{\sqrt{1-x^2}} = \int -\frac{\sin(t)dt}{\sin(t)} \quad (37)$$

$$= -t \quad (38)$$

따라서 적분의 값은 \cos 의 역함수가 된다.

치환적분의 예시 : 삼각함수로의 치환

$\int \sqrt{\frac{ax}{1-x}} dx$ 를 생각해 보자!

야코비안과 야코비안의 판별식 I

어떤 벡터함수 $\vec{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 의 Jacobian은 다음과 같이 정의된다.

$$J = \left[\frac{\partial \vec{f}}{\partial x_1} \cdots \frac{\partial \vec{f}}{\partial x_n} \right] = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \cdots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix} \quad (39)$$

야코비안은 일종의 일반화된 ∇ 라고 할 수 있다. 또한, $n=m$ 인 경우의 Jacobian의 행렬식은 다중적분에서 중요한 의미를 가진다.

일반화된 좌표계에서의 다중적분

직교좌표에서의 다중적분 $\int \int \int g(x, y, z) dx dy dz$ 를 생각해 보자. 이 때, 우리가 새로운 좌표계 (p, q, r) 을 도입하고, p, q, r 과 x, y, z 간의 상관관계를 나타내는 함수를 \vec{f} 라 하자. 즉, $\vec{f}(x, y, z) = (p, q, r)$ 이다. 이 때, 위 다중적분을 우리가 새로 만든 좌표계로 바꾸어 시행하면 다음과 같다.

$$\int \int \int g(x, y, z) dx dy dz = \int \int \int h(p, q, r) |det(J_{\vec{f}})| dp dq dr \quad (40)$$

이다.

$e^{-\alpha x^2}$ 의 적분

x, y 좌표계에서 $r = x^2 + y^2$ 과 $\theta = \arctan(\frac{y}{x})$ 로 바꾸어 적분을 진행하면 된다.

미분방정식과 차수 I

미분은 선형변환이다. 즉,

$$\frac{d}{dx}(af(x) + bg(x)) = a\frac{df}{dx} + b\frac{dg}{dx} \quad (41)$$

이 성립한다. 한번 미분이 선형변환이므로, 여러 번 미분한 것이나 여러 번의 미분연산의 선형결합 또한 다 선형변환이 된다. 즉,

$$D = \sum_{i=0}^n a_i \frac{d^n}{d^n x} \quad (42)$$

$$L = \sum_{i=0}^n p_i(x) \frac{d^n}{d^n x} \quad (43)$$

는 선형변환이다. 이 때, L을 p차 미분연산자라고 한다. 여기서 $p_i(x)$ 는 임의의 x에 대한 함수이다. 이 때, 아래와 같은 꼴의 식을 선형 미분방정식이라고 한다.

$$Lf(x) = F(x) \quad (44)$$

이 때, L 이 1차 미분연산자이면 1차 미분방정식이라고 한다. 일반적으로, 1차 미분방정식의 경우 초기조건 $f(x_0)$ 가 주어져야 함수 $f(x)$ 를 정확하게 특정할 수 있으며, n 차 미분방정식의 경우 $f^{(i)}(x_{0i})$ 의 초기조건이 주어져야 한다.

Seperable Equations

다음과 같은 꼴로 변형이 가능한 1차 미분방정식을 분리 가능(seperable)하다고 한다.

$$g(y)\frac{dy}{dx} = f(x) \quad (45)$$

이러한 함수의 경우, 양변을 x 로 적분하면

$$\int g(y)dy = \int f(x)dx \quad (46)$$

이므로 $s(x, y) = F(x) - G(y) = 0$ 꼴의 해를 항상 얻을 수 있다.

Example

$$\frac{dy}{dx} = \frac{y}{2} = \frac{3}{2}, y(0) = 2 \quad (47)$$

에서 y 를 구해보자. 다음과 같은 변형을 통해 우선 변수를 분리한다.

$$\frac{dy}{dx} = \frac{3-y}{2} \quad (48)$$

$$\frac{2}{3-y} \frac{dy}{dx} = 1 \quad (49)$$

$$\int \frac{2dy}{3-y} = \int dx \quad (50)$$

$$C - \ln(3-y) = x \quad (51)$$

$$y = 3 - e^{C-x} \quad (52)$$

로 풀 수 있다. C 는 초기조건을 이용하여 구할 수 있다.

선형 미분방정식

일반적으로 선형 미분방정식은 다음과 같은 꼴을 띈다.

$$Lf(x) = \sum_{i=0}^n p_i(x) \frac{d^n f}{d^n x} = g(x) \quad (53)$$

이 때, L 이 1차 미분연산자이면 이를 1차 선형 미분방정식이라고 한다.

1차 선형 미분방정식의 해법

1차 선형 미분방정식은 다음의 꼴을 가진다.

$$\frac{dy}{dx} + p(x)y = g(x) \quad (54)$$

이 때, 어떠한 함수 $\mu(x)$ 가 있어 다음을 만족시킨다고 하자.

$$\mu(x)\left(\frac{dy}{dx} + p(x)y\right) = \mu(x)g(x) \quad (55)$$

$$\mu(x)\left(\frac{dy}{dx} + p(x)y\right) = \frac{d}{dx}(\mu(x)g(x)) \quad (56)$$

이런 경우, y 와 μ 는 각각 다음의 꼴을 가지게 된다.

$$y = \frac{1}{\mu(x)} \int \mu(x)g(x)dx \quad (57)$$

$$\mu(x) = Ce^{\int p(x)dx} \quad (58)$$

Characteristic Polynomial

n 차 선형 미분연산자 중 계수가 상수인 경우, 그 미분연산자의 특성방정식은 다음과 같이 정의된다.

L 의 특성방정식

$L = \sum_{i=0}^n p_i \frac{d^n}{d^n x}$ 의 특성방정식은 $p(x) = \sum_i p_i x^i$ 이다.

이 때, $Lf(x) = 0$ 의 해는 특성방정식의 해 α_i 에 대해서, $e^{\alpha_i x}$ 의 선형결합이다.

라플라스 변환 I

함수 f 의 라플라스 변환은 다음과 같이 정의된다.

라플라스 변환

$$F(s) = L(f(t)) = \int_0^{\infty} e^{-st} f(t) dt$$

라플라스 변환은 다음의 성질들을 가진다.

- 선형이다. 즉, $L(af(t) + bg(t)) = aL(f(t)) + bL(g(t))$ 이다.
- $L(t^n f(t)) = (-1)^n F^{(n)}(s)$
- $L\left(\frac{df}{dt}\right) = sF(s) - f(0)$
- $L\left(\frac{d^n f}{dt^n}\right) = s^n F(s) - s^{(n-k)} f^{(k-1)}(0)$

라플라스 변환과 미분방정식의 풀이 I

다음 미분방정식을 생각하자.

$$x'' - x' - 2x = 0 \quad (59)$$

이를 푸는 기존의 방법은 특성방정식 $t^2 - t - 2 = 0$ 을 풀어, 그 근을 이용하여 해를 구하는 것이었다. 이번에는 라플라스 변환을 이용해서 구해보도록 할 것이다.

먼저, $X(s) = L(x(t))$ 라 하자. 그러면 라플라스 변환 규칙에 따라 다음이 성립한다.

$$[s^2X(s) - sx(0) - x'(0)] - [sX(s) - x(0)] - 2X(s) = 0 \quad (60)$$

$$X(s) = \frac{s-1}{(s-2)(s+1)} \quad (61)$$

라플라스 변환과 미분방정식의 풀이 II

이에 따라서, 결국 $x(t)$ 를 구하는 것은 라플라스 역변환을 하는 것과 같아진다. 이는 우변이 0이 아닐 때 더욱 편하게 풀이 가능하다. 다음의 미분방정식을 보자.

$$x'' + x' = \sin(2t) \quad (62)$$

이 경우, 위와 같은 방식으로 하면 결국

$$X(s) = \frac{2s + 1}{s^2 + 1} + \frac{2}{3(s^2 + 1)} - \frac{2}{3(s^2 + 4)} \quad (63)$$

과 같이 되어, 기존 방식보다 문제를 용이하게 해결할 수 있다.

이전의 수업에서 sin의 급수로 임의의 함수를 표현하는 것을 보았다.
이번에는 비슷하게 exponential 함수를 이용하여 표현하는 것을 볼 것이다.
어떤 함수 $f(t)$ 에 대하여, 주어진 상수 T 에 대해서 다음이 성립한다.

$$f(t) = \sum_{n=-\infty}^{\infty} c_n e^{\frac{2\pi i n t}{T}} \quad (64)$$

이 때, c_n 은

$$c_n = \frac{1}{T} \int_0^T f(t) e^{-\frac{2\pi i n t}{T}} dt \quad (65)$$

이며, $c_n = c_{-n}^*$ 이 성립한다.

다음의 두 가지를 보여라.

- c_n 이 왜 저렇게 되는지 보여라.
- $f(t) = \cos(4\pi t)$ 의 경우, $T = 0.5$ 로 할 때 c_n 을 구하라. 이 때, n 이 1일 때와 아닐 때를 나누어 구해야 할 것이다.

Fourier Transform I

위 푸리에 급수에서 c_n 을 구하는 과정을 Fourier Transform이라고 한다. 즉,

Fourier Transform

Fourier Transform F 는 다음과 같다.

$$F(g(t)) = \int_{-\infty}^{\infty} g(t)e^{(-2\pi ift)}dt$$

또한, Inverse Fourier Transform F^{-1} 은 다음과 같이 주어진다.

$$F^{-1}(G(f)) = \int_{-\infty}^{\infty} G(f)e^{(2\pi ift)}dt$$

푸리에 변환은 다음의 성질들을 만족한다.

- 선형이다. 즉, $F(af(t) + bg(t)) = aF(f(t)) + bF(g(t))$ 이다.
- $F(f(t - a)) = e^{-2\pi ifa}F(f(t))$
- $F(f(ct)) = \frac{F(\frac{f}{c})}{|c|}$
- $F(\frac{df}{dt}) = 2\pi ifF(t)$
- $F(\int_{-\infty}^t f(\tau)d\tau) = \frac{F(f(t))}{2\pi if}$

- $F(f(t)g(t)) = F(f(t)) * F(g(t))$. 여기서,
 $f * g(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$ 이다.

Fourier Transform : examples

- $F(\delta(t - a)) = e^{-2\pi fia}$
- $F(e^{2\pi ait}) = \delta(x - a)$

Fourier Transform and Differential Equations

어떤 상수 계수 미분방정식 $Lf(t) = g(t)$ 가 있다고 하자. 이 때, $L = p_n \frac{d^n}{dt^n}$ 이다. 양변에 Fourier Transform을 취하면 다음과 같다.

$$(p_n(2\pi if)^n)F(f(t)) = F(g(t)) \quad (66)$$

따라서,

$$F(f(t)) = \frac{F(g(t))}{p_n(2\pi if)^n} \quad (67)$$

$$f(t) = F^{-1} \frac{F(g(t))}{p_n(2\pi if)^n} \quad (68)$$

로, 미분방정식의 풀이를 적분과 사칙연산으로 해결할 수 있다.

범함수란 함수를 인자로 받는 함수를 말한다. 프로그래밍에서 lambda로 함수를 인자로 넘기는 것과 완벽하게 같은 개념이다. 우리는 여기서는 다소 단순한, 일변수함수 f 와 그 도함수 f' 을 인자로 가지는 범함수 F 를 생각할 것이다. 조금 더 자세하게는, 다음과 같은 꼴의 범함수를 생각하고자 한다.

$$F = \int_{x_1}^{x_2} h(f, f'; x) dx \quad (69)$$

위와 같이 범함수 F 를 정의했을 때, 다음과 같은 조건을 만족하는 함수 h 가 범함수의 극값을 만들어준다.

$$\frac{\partial h}{\partial f} = \frac{d}{dx} \frac{\partial h}{\partial f'} \quad (70)$$

극값을 주는 함수를 $f(x)$ 라고 하자. 이 때, f 에 약간의 변화 $\alpha\eta(x)$ 를 주어, $f(\alpha, x) = f(0, x) + \alpha\eta(x)$ 를 생각하자. 이 때, 다음이 성립하도록 η 함수를 잡는다.

$$\eta(x_1) = \eta(x_2) = 0 \quad (71)$$

위 F 를 α 로 편미분하면 다음과 같다.

$$\frac{\partial F}{\partial \alpha} = \frac{\partial}{\partial \alpha} \int_{x_1}^{x_2} h(f, f'; x) dx \quad (72)$$

$$= \int_{x_1}^{x_2} \frac{\partial f}{\partial \alpha} \frac{\partial h}{\partial f} + \frac{\partial h}{\partial f'} \frac{\partial f'}{\partial \alpha} dx \quad (73)$$

이 때, 위에서 η 의 정의와 f 의 정의에 의해서 다음이 성립한다.

$$\frac{\partial f}{\partial \alpha} = \eta(x) \quad (74)$$

$$\frac{\partial f'}{\partial \alpha} = \frac{\partial \eta}{\partial x} \quad (75)$$

위 f 와 f' 의 계산을 대입하면 아래와 같다.

$$\frac{\partial F}{\partial \alpha} = \int_{x_1}^{x_2} \eta(x) \frac{\partial h}{\partial f} + \frac{\partial h}{\partial f'} \frac{\partial \eta}{\partial x} dx \quad (76)$$

위 식에서, 부분적분법을 이용하여 두 번째 항을 전개하면 아래와 같다.

$$\frac{\partial F}{\partial \alpha} = \left[\frac{\partial h}{\partial f} \eta(x) \right]_{x_1}^{x_2} + \int_{x_1}^{x_2} \left[\eta(x) \frac{\partial h}{\partial f} - \frac{d}{dx} \left(\frac{\partial h}{\partial f'} \right) \eta(x) \right] dx \quad (77)$$

여기서 위 η 에 대한 조건을 대입하여 정리하면, 아래와 같다.


$$\frac{\partial F}{\partial \alpha} = \int_{x_1}^{x_2} \eta(x) \left[\frac{\partial h}{\partial f} - \frac{d}{dx} \frac{\partial h}{\partial f'} \right] dx \quad (78)$$

위 식에서 우리는 이미 y 가 $\alpha = 0$ 일 때 극점을 가지고 있음을 알고 있다. 즉, $\frac{\partial F}{\partial \alpha}(\alpha = 0) = 0$ 이어야 한다. η 는 위 식을 만족하는 임의의 함수이므로 결국 위 식이 0이 되기 위해서는 라그랑지 조건이 성립한다.

최단거리 곡선

2차원에서의 두 점 $P(x_1, y_1)$, $Q(x_2, y_2)$ 를 잇는 최단거리의 곡선이 직선임을 보여라. 이 때, 곡선의 길이가 $\int_{x=x_1}^{x=x_2} \sqrt{1 + (y'(x))^2} dx$ 임을 이용하라.

최단시간 강하 곡선 : Brachistochrone problem



낙하 시간은 $\int_{y=0}^{y=h} \sqrt{\frac{1+(x'(y))^2}{y}} dy$ 이다. 이 때, 적당한 상수 a에 대해서 $x = a(\theta - \sin(\theta))$, $y = a(1 - \cos(\theta))$ 가 되어 사이클로이드가 된다.